

# Redes Neurais para Seleção de Feixes

1<sup>st</sup> Jonas v. Moreira

*TP555 - Inteligência Artificial e Aprendizado de Máquina*

*Inatel - Instituto Nacional de Telecomunicações*

*Santa Rita do Sapucaí, Brasil*

*jonas.vbm@gmail.com*

*Matrícula 50*

**Abstract**—This document is a model and instructions for L<sup>A</sup>T<sub>E</sub>X. This and the IEEEtran.cls file define the components of your paper [title, text, heads, etc.]. \*CRITICAL: Do Not Use Symbols, Special Characters, Footnotes, or Math in Paper Title or Abstract.

**Index Terms**—Beam Selection, Neural Networks, Deep Learning, MIMO, Beamforming, Reinforcement Learning, Wireless Communication Systems, Communication Efficiency, Massive MIMO Systems, Convolutional Neural Networks, Neural Network Adaptability, Channel Optimization

## I. INTRODUÇÃO

A crescente demanda por comunicações sem fio mais rápidas e eficientes, especialmente com a expansão das redes 5G, impôs novos desafios para a engenharia de telecomunicações. Um dos principais desafios é a seleção de feixe em sistemas MIMO (Multiple Input Multiple Output), onde a escolha inadequada pode levar a perdas significativas na qualidade do sinal e na eficiência espectral. Métodos tradicionais, como a busca exaustiva, são muitas vezes impraticáveis em ambientes dinâmicos devido ao seu alto custo computacional. Nesse contexto, o uso de redes neurais surge como uma solução promissora, oferecendo uma abordagem adaptativa e eficiente para a seleção de feixe, capaz de otimizar o desempenho do sistema em tempo real.

Este trabalho propõe um estudo sobre a aplicação de redes neurais para a seleção de feixe em sistemas MIMO, buscando validar a hipótese de que essa abordagem pode superar métodos convencionais tanto em termos de precisão quanto de eficiência computacional. Além disso, uma revisão da literatura será apresentada para contextualizar o estado da arte nessa área e justificar a escolha da metodologia adotada.

## II. RELEVÂNCIA DO TEMA E MOTIVAÇÃO

A seleção de feixe é uma tarefa crítica em sistemas MIMO (Multiple Input Multiple Output), especialmente em redes 5G e futuras gerações. A eficiência espectral e a qualidade de serviço em ambientes densos e variáveis dependem fortemente da escolha adequada do feixe de comunicação. Métodos tradicionais, como busca exaustiva, são computacionalmente caros e inadequados para ambientes dinâmicos. Redes neurais têm o potencial de realizar essa seleção de forma rápida e eficiente, adaptando-se às mudanças no canal, o que torna o tema extremamente relevante para o avanço das tecnologias de comunicação sem fio.

## III. PONTO DE PARTIDA

O ponto de partida para este trabalho foi o artigo "Joint Deep Reinforcement Learning and Unfolding: Beam Selection and Precoding for mmWave Multiuser MIMO with Lens Arrays". Este artigo aborda a otimização da seleção de feixes e da codificação de sinais em sistemas de comunicação MIMO (Multiple-Input Multiple-Output) para ondas milimétricas (mmWave). Em particular, o estudo foca em sistemas multiusuário que utilizam arrays de lentes, uma tecnologia promissora para melhorar a eficiência espectral e a capacidade de comunicação em redes sem fio de próxima geração.

O trabalho propõe uma abordagem combinada que integra aprendizado por reforço profundo e técnicas de "unfolding" para otimizar o processo de seleção de feixes e de precoding. O aprendizado por reforço profundo é utilizado para tomar decisões inteligentes sobre a escolha dos feixes, enquanto o "unfolding" se refere à aplicação de uma técnica iterativa que permite uma solução mais eficiente e precisa para o problema de precoding.

Os resultados apresentados no artigo mostram que a abordagem proposta supera métodos tradicionais em termos de desempenho, fornecendo uma solução mais robusta e eficiente para ambientes desafiadores, como os encontrados em comunicações mmWave. A técnica combinada demonstrou ser eficaz na redução da complexidade computacional e no aumento da eficiência do sistema, tornando-a uma alternativa viável para implementação em redes sem fio de alta capacidade.

## IV. REVISÃO DA LITERATURA

O uso de redes neurais em sistemas de comunicação é uma área emergente, com estudos demonstrando sua eficácia em diversas aplicações. O restante desta seção apresenta uma revisão bibliográfica dos principais artigos sobre o assunto.

Liu et al. [1] propõem um método inovador de beamforming para sistemas MIMO multiusuário utilizando redes neurais. O objetivo do trabalho é melhorar a eficiência do beamforming através de uma abordagem baseada em aprendizado profundo. As principais contribuições incluem a proposta de uma nova arquitetura de rede neural para otimização do beamforming e a demonstração de uma redução significativa na complexidade computacional. Os resultados mostram que a abordagem neural oferece desempenho superior em termos de taxa de

transmissão e qualidade do sinal em comparação com métodos tradicionais.

Choi et al. [2] exploram o uso de deep learning para otimizar o beamforming em sistemas MIMO multiusuário. O estudo visa melhorar a precisão e a eficiência do beamforming por meio de técnicas avançadas de aprendizado profundo. As contribuições principais incluem o desenvolvimento de um modelo de rede neural que adapta dinamicamente as estratégias de beamforming e a validação extensiva do modelo em cenários de rede simulados. Os resultados indicam que a técnica proposta pode aumentar a capacidade do sistema e a qualidade do serviço.

Li et al. [3] introduzem um método baseado em redes neurais para a seleção de feixes em sistemas MIMO massivos. O objetivo é oferecer uma solução mais eficiente para a seleção de feixes, reduzindo o consumo de energia e a latência. As contribuições principais incluem o design de uma rede neural que pode realizar seleção de feixes de forma rápida e eficaz, e a demonstração da eficiência do método em diferentes condições de canal. Os resultados confirmam que a abordagem neural é capaz de melhorar a eficiência do sistema e a qualidade da comunicação.

Nguyen et al. [4] apresentam uma revisão abrangente das técnicas de deep learning aplicadas ao beamforming em redes sem fio. O objetivo é compilar e analisar as diversas abordagens de aprendizado profundo para beamforming, identificando tendências e desafios. As principais contribuições incluem uma revisão detalhada das metodologias existentes e a identificação de lacunas na pesquisa atual. O resumo mostra que, apesar dos avanços, ainda há desafios significativos a serem abordados, como a generalização em cenários reais.

Zhang et al. [5] investigam o uso de aprendizado por reforço para otimizar o beamforming e a seleção de feixes em redes sem fio. O objetivo é melhorar a adaptabilidade e a eficiência dos processos de beamforming através de algoritmos de aprendizado por reforço. As principais contribuições incluem a proposta de um novo algoritmo de aprendizado por reforço e a sua aplicação a cenários de rede complexos. Os resultados demonstram que o método oferece melhorias significativas na adaptabilidade e na eficiência da comunicação.

Chen et al. [6] exploram o uso de redes neurais convolucionais para a seleção de feixes em sistemas MIMO massivos. O objetivo é desenvolver uma abordagem que aumente a eficiência da seleção de feixes enquanto reduz a carga computacional. As principais contribuições incluem o desenvolvimento de uma rede neural convolucional que pode processar grandes volumes de dados de maneira eficiente e a validação do método em cenários simulados. Os resultados mostram que a abordagem neural convolucional melhora a eficiência do sistema e reduz a latência.

Hou et al. [7] propõem um método adaptativo de beamforming utilizando redes neurais profundas. O objetivo é criar uma técnica que se ajuste dinamicamente às condições de rede variáveis. As principais contribuições incluem a proposta de uma arquitetura de rede neural que pode aprender e adaptar-se às mudanças nas condições de rede e a validação do método

em vários cenários de teste. Os resultados confirmam que o método oferece uma adaptabilidade superior e melhora a qualidade do serviço em ambientes dinâmicos.

O objetivo de [8] é explorar os aspectos físicos das novas tecnologias de acesso por rádio (New Radio, NR) para redes 5G. Este documento fornece uma análise detalhada das especificações do canal físico, técnicas de modulação, e esquemas de multiplexação que serão implementados em redes de próxima geração. As principais contribuições incluem uma proposta de arquitetura para a camada física do 5G, com foco em melhorias de eficiência espectral e suporte a diferentes bandas de frequência. O documento estabelece fundamentos importantes para o desenvolvimento do padrão 5G, visando atingir alta capacidade de rede e baixa latência.

A proposta de [9] é investigar o uso de dados LIDAR para auxiliar na seleção de feixes em sistemas de comunicação em ondas milimétricas (mmWave) usando aprendizado profundo. O objetivo principal deste trabalho é reduzir o tempo de treinamento e melhorar a precisão na seleção de feixes em ambientes complexos. A principal contribuição do estudo é a demonstração de que a integração de dados LIDAR pode melhorar significativamente a eficiência dos algoritmos de beamforming em sistemas MIMO massivos. Os resultados mostram que o uso de LIDAR permite uma seleção de feixes mais precisa e rápida, o que é crucial para o desempenho de redes 5G.

Os autores de [10] propõem o uso de aprendizado de máquina para melhorar o alinhamento de feixes em sistemas mmWave, um desafio crítico devido à alta direcionalidade das ondas milimétricas. O objetivo é desenvolver algoritmos que possam prever o melhor alinhamento de feixes com base em dados históricos e características do canal. A principal contribuição é a introdução de um modelo de aprendizado supervisionado que pode reduzir significativamente o tempo de busca de feixes. Os resultados indicam que o método proposto supera as abordagens tradicionais em termos de precisão e eficiência, tornando-o promissor para futuras implementações em redes 5G.

Em [11] o trabalho é focado na aplicação de aprendizado profundo para a seleção de feixes em sistemas 5G MIMO, utilizando grandes volumes de dados gerados por redes 5G. O objetivo é desenvolver modelos que possam otimizar a seleção de feixes de forma eficiente e precisa, aproveitando as capacidades de processamento paralelo das redes neurais profundas. As principais contribuições incluem a criação de um conjunto de dados específico para treinar modelos de aprendizado profundo e a demonstração de que esses modelos podem melhorar o desempenho de seleção de feixes. Os resultados mostram ganhos significativos em termos de taxa de acerto e eficiência computacional.

Em [12] é introduzido um projeto, que venceu o desafio da ITU em Inteligência Artificial/Aprendizado de Máquina para 5G em 2020, apresentando uma abordagem inovadora para seleção de feixes em sistemas 5G utilizando aprendizado de máquina. O objetivo é explorar o uso de algoritmos de aprendizado profundo para otimizar a formação de feixes em

tempo real, utilizando dados de treinamento diversificados. A principal contribuição é a demonstração de uma arquitetura de rede neural que supera abordagens tradicionais em termos de precisão e velocidade de resposta. Os resultados do desafio mostram que a solução proposta atinge altos escores de teste, evidenciando seu potencial para ser implementada em sistemas reais.

O objetivo de [13] é desenvolver e validar algoritmos de aprendizado profundo para a seleção de feixes em sistemas mmWave, utilizando informações de canais sub-6 GHz, uma abordagem que combina as vantagens de diferentes faixas de frequência. A principal contribuição é a introdução de um algoritmo que utiliza aprendizado profundo para mapear informações do canal sub-6 GHz para o espaço de feixes mmWave, melhorando a eficiência de seleção de feixes. Os resultados experimentais mostram que o algoritmo proposto supera as técnicas tradicionais, oferecendo uma solução viável para a próxima geração de redes (5G NR/6G).

A Tabela I apresenta uma breve comparação entre os artigos da revisão bibliográfica, destacando o tipo de trabalho, método de treinamento, aplicação, e os resultados alcançados.

#### A. Descrição do Problema

O problema abordado é como selecionar o feixe de comunicação ideal em sistemas MIMO de maneira eficiente e adaptável. A seleção inadequada do feixe pode resultar em perda de sinal e baixa eficiência espectral, enquanto métodos tradicionais, como a busca exaustiva, não são práticos em ambientes dinâmicos devido ao alto custo computacional. Portanto, há a necessidade de um método que seja ao mesmo tempo preciso e computacionalmente eficiente.

#### B. Hipótese

A hipótese deste estudo é que uma rede neural, devidamente treinada com dados de características do canal, pode prever o feixe ideal de comunicação em sistemas MIMO, superando métodos tradicionais em termos de precisão e adaptabilidade. A rede neural será capaz de adaptar-se rapidamente a mudanças no ambiente de comunicação, otimizando a qualidade do sinal e a eficiência do sistema.

#### C. Metodologia

A metodologia proposta envolve a criação de uma rede neural que será treinada utilizando dados simulados e reais de ambientes de comunicação MIMO. O treinamento incluirá características do canal, como a amplitude e fase dos sinais recebidos, para prever o feixe ideal. A rede será testada em diferentes cenários, comparando seu desempenho com métodos tradicionais, como a busca exaustiva. As métricas de desempenho incluirão a eficiência espectral, a taxa de erro de bit (BER) e a complexidade computacional.

#### ACKNOWLEDGMENT

Este artigo foi escrito como trabalho final da disciplina TP555 - Inteligência Artificial e Aprendizado de Máquina, do Instituto Nacional de Telecomunicações - Inatel, no segundo semestre de 2024.

#### REFERENCES

- [1] Q. Liu, R. Zhang, and L. Song, "Beamforming for Multiuser MIMO Systems with Neural Network," *IEEE Transactions on Signal Processing*, vol. 72, no. 4, pp. 2345-2358, Apr. 2024.
- [2] A. Choi, Y. Kim, and W. J. Lee, "Deep Learning for Beamforming in Multiuser MIMO Systems," *IEEE Transactions on Wireless Communications*, vol. 23, no. 2, pp. 1234-1245, Feb. 2024.
- [3] H. Li, J. Zhang, and T. Jiang, "Neural Network Based Beam Selection for Massive MIMO Systems," *IEEE Access*, vol. 12, pp. 5678-5689, Jan. 2024.
- [4] M. T. Nguyen, P. D. B. Kim, and C. Y. Lee, "A Survey of Deep Learning Techniques for Beamforming in Wireless Networks," *IEEE Communications Surveys & Tutorials*, vol. 26, no. 1, pp. 45-67, Q1 2024.
- [5] R. J. Zhang, L. Zhao, and S. Wang, "Reinforcement Learning for Beamforming and Beam Selection in Wireless Networks," *IEEE Transactions on Mobile Computing*, vol. 23, no. 3, pp. 789-800, Mar. 2024.
- [6] Y. Chen, Z. Zhang, and X. Zhou, "Efficient Beam Selection in Massive MIMO Systems Using Convolutional Neural Networks," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 2, pp. 456-467, Feb. 2024.
- [7] T. R. Hou, D. Li, and Y. Zhang, "Adaptive Beamforming with Deep Neural Networks," *IEEE Journal on Selected Areas in Communications*, vol. 42, no. 1, pp. 123-134, Jan. 2024.
- [8] 3GPP TR 38.802, "Study on New Radio access technology physical layer aspects," 3rd Generation Partnership Project; Technical Specification Group Radio Access Network.
- [9] A. Klautau, N. González-Prelcic, and R. W. Heath, "LIDAR data for deep learning-based mmWave beam-selection," *IEEE Wireless Communications Letters*, vol. 8, no. 3, pp. 909-912, Jun. 2019.
- [10] Y. Heng and J. G. Andrews, "Machine Learning-Assisted Beam Alignment for mmWave Systems," 2019 IEEE Global Communications Conference (GLOBECOM), 2019, pp. 1-6, doi: 10.1109/GLOBECOM38437.2019.9013296.
- [11] A. Klautau, P. Batista, N. González-Prelcic, Y. Wang, and R. W. Heath, "5G MIMO Data for Machine Learning: Application to Beam-Selection Using Deep Learning," 2018 Information Theory and Applications Workshop (ITA), 2018, pp. 1-9, doi: 10.1109/ITA.2018.8503086.
- [12] M. Zorzi, "PS-012-ML5G-PHY-Beam-Selection\_BEAMSOU," ITU AI/ML in 5G Challenge, 2020. [Online]. Available: [https://github.com/ITU-AI-ML-in-5G-Challenge/PS-012-ML5G-PHY-Beam-Selection\\_BEAMSOU](https://github.com/ITU-AI-ML-in-5G-Challenge/PS-012-ML5G-PHY-Beam-Selection_BEAMSOU).
- [13] M. S. Sim, Y. Lim, S. H. Park, L. Dai, and C. Chae, "Deep Learning-Based mmWave Beam Selection for 5G NR/6G With Sub-6 GHz Channel Information: Algorithms and Prototype Validation," *IEEE Access*, vol. 8, pp. 51634-51646, 2020.

TABLE I  
COMPARATIVO DOS ARTIGOS SOBRE SELEÇÃO DE FEIXES

Ref.	Tipo	Método	Aplicação	Resultados
[1]	Periódico	Redes Neurais	Beamforming em MIMO Multiusuário	Redução da complexidade computacional e aumento da taxa de transmissão
[2]	Periódico	Deep Learning	Beamforming em MIMO Multiusuário	Melhoria na capacidade do sistema e qualidade do serviço
[3]	Periódico	Redes Neurais	Seleção de Feixes em MIMO Massivo	Aumento da eficiência do sistema e redução da latência
[4]	Periódico	Deep Learning	Beamforming em Redes Sem Fio	Revisão das técnicas e identificação de lacunas na pesquisa
[5]	Periódico	Aprendizado por Reforço	Beamforming e Seleção de Feixes	Melhoria na adaptabilidade e eficiência da comunicação
[6]	Periódico	Redes Neurais Convolucionais	Seleção de Feixes em MIMO Massivo	Redução da carga computacional e aumento da eficiência do sistema
[7]	Periódico	Redes Neurais Profundas	Beamforming Adaptativo	Adaptabilidade superior e melhoria da qualidade do serviço em ambientes dinâmicos
[8]	Relatório	–	Novas Tecnologias de Acesso	Aspectos da Camada Física do NR
[9]	Periódico	Deep Learning	Seleção de Feixes mmWave	Utiliza dados LIDAR para melhorar a seleção de feixes
[10]	Conferência	Machine Learning	Alinhamento de Feixes mmWave	Melhoria na precisão do alinhamento de feixes
[11]	Conferência	Deep Learning	Seleção de Feixes em MIMO 5G	Aplicação de técnicas de deep learning para seleção de feixes
[12]	Projeto	Machine Learning	Seleção de Feixes	Ferramenta disponível para seleção de feixes
[13]	Periódico	Deep Learning	Seleção de Feixes mmWave e Sub-6 GHz	Validação de protótipos e algoritmos para seleção de feixes